西安交通大学
XI'AN JIAOTONG UNIVERSITY

CSCC 全国大学生计算机系统能力大赛

基于GPU的服务资源卸载技术探索

GPUC——面向透明存储压缩的GPU解压卸载原型

2026 全国大学生计算机系统能力大赛 — OS 功能挑战赛道

西安交通大学 · 队伍 **404notfound**

成员：朱嘉乐（队长）、贾茹、边程曦

指导老师：聂世强、刘松

➢ 项目概览——透明存储压缩原型已跑通，三类平台完成验证

完成了什么

1 完整系统链路

Hook透明接入 ➤ RAW后台压缩 ➤ CPU/GPU解压

2 自研算法与工程机制

- SGLZ 自研算法
- 自描述文件格式
- 前后台解耦
- 长期GPU Worker

3 三类硬件平台

PASS	PASS	PASS
Tesla V100	RTX 4090	鲲鹏920+智铠100
NVIDIA · sm_70	NVIDIA · sm_89	AArch64 · 国产 GPU

已完成：写入 → 后台压缩 → 透明读取 → 校验与回退

现有交付与验证材料

16	8134	92
源码与头文件	行核心代码	测试文件
include/ + src/	含注释与空行	tests/

3	93	4
验证平台	正式结果目录	证据维度
V100 / 4090 / 国产	results/final/	功能·性能·稳定·资源

验证闭环

✓ 功能	✓ 性能	✓ 稳定	✓ 资源
POSIX / CRC / SHA	fio / Vdbench / SQLite	1 小时 · 故障 5/5	CPU / DRAM / GPU

用户态原型已跑通，验证材料可追溯

CSCC 全国大学生
计算机系统能力大赛

目录

CONTENTS

01 问题与背景

02 解决方案

03 创新设计

04 实验结果

05 团队与总结

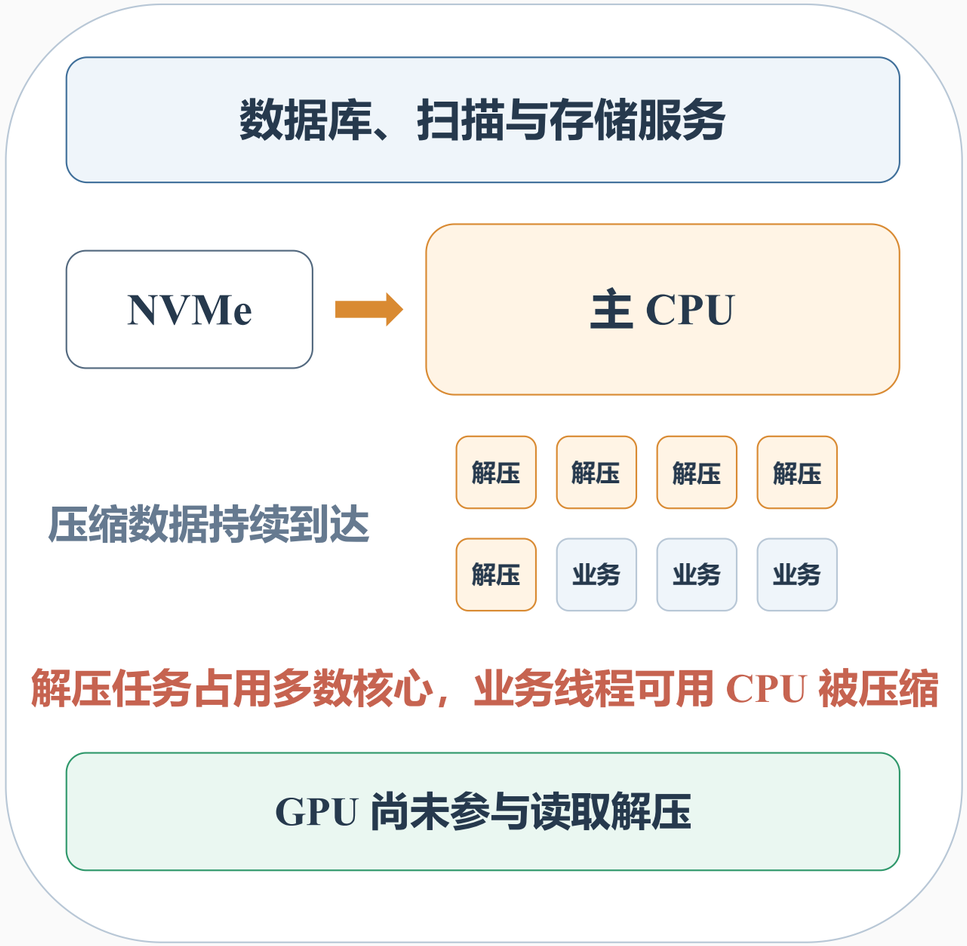
01

问题与背景

为什么存储压缩会形成 CPU 资源问题？本项目为什么先选择用户态入口？

01 问题与背景——压缩节省存储，但解压会占用业务 CPU

真实场景：数据库与存储服务共机运行



压缩的交换

减少空间与传输量，但读取时增加解压计算。

瓶颈的转移

NVMe 与页缓存变快后，解压更容易进入关键路径。

共机的争用

CPU 解压与业务争夺核心，并增加主机内存访问。

Song 等[1]指出：压缩进入读写关键路径后会阻塞用户 I/O，因此应尽量与前台请求解耦。

Peñaranda 等[2]指出：GPU 更适合较大数据，小任务可能由 CPU 处理更快，因此需要按任务规模选择后端。

核心问题：同等解压工作量下，GPU能否释放主CPU，让业务获得更多CPU资源?

01 问题与背景——现有压缩路线各有取舍，本项目先验证机制可行性

背景判断：存储压缩可以落在不同系统层次，透明范围、部署成本和工程复杂度并不相同。

三种系统落点及论文依据

Device Mapper / 块层

- 对 ext4/XFS 较透明，但需自行处理块映射和一致性恢复。
- Tan 与 Zhu[3]说明 Device Mapper 可以通过逻辑—物理映射向上提供标准块设备。

Btrfs / OpenZFS 文件系统层

- 原生集成 CoW、校验、快照和透明压缩，但使用时绑定文件系统。
- Dakic 等[4]指出，文件系统选择取决于具体数据访问需求。

用户态机制原型

- 无需修改内核，适合快速验证机制，但透明范围有限。
- Cho 等[5]指出，用户态开发更灵活，但内核—用户态通信会产生额外开销。

项目定位：本项目选择用户态入口回答“机制是否可行、在什么条件下有收益”

02

解决方案

从整体架构、透明语义、文件格式、计算后端和读写路径说明原型如何工作。

02 解决方案——系统把应用访问、后台压缩和读取解压分开

业务继续使用原有 POSIX 接口，写入、后台压缩与读取解压彼此分离

应用层

- 数据库（SQLite）
- 存储测试（fio）
- 并发测试（Vdbench）
- 普通 POSIX 应用

↓

透明访问层

- LD_PRELOAD Hook：接管常用文件访问，维护逻辑长度、偏移与读取语义

↓

核心处理层

1. 写入：应用写入 → 写入 RAW 文件 → 保留逻辑内容 → 立即返回
2. 后台压缩：后台扫描 → 批量压缩 → 生成临时文件 → 原子替换
3. 透明读取：识别压缩对象 → CPU 或 GPU 解压 → 校验与回退 → 返回数据

↓

资源与数据层

- NVMe 与页缓存
- 主机内存
- GPU 显存与工作进程

业务继续使用原有 POSIX 接口；压缩发生时间与解压计算后端可以独立调整。

02 解决方案——透明语义让应用看到原始内容和逻辑大小

物理文件可以压缩，但应用仍按原始文件解释长度、偏移和读取内容

已接入的常用接口

open	read / pread	fstat / lseek	mmap

应用可见能力	普通文件	GPUC 压缩对象
访问方式	POSIX 接口	POSIX 接口
文件大小	物理大小	原始逻辑大小
读取结果	原始内容	解压后的原始内容
破坏性写入	允许	返回 EROFS

Hook 维护的信息

- 对象格式与文件描述符状态
- 逻辑偏移、逻辑长度与只读状态

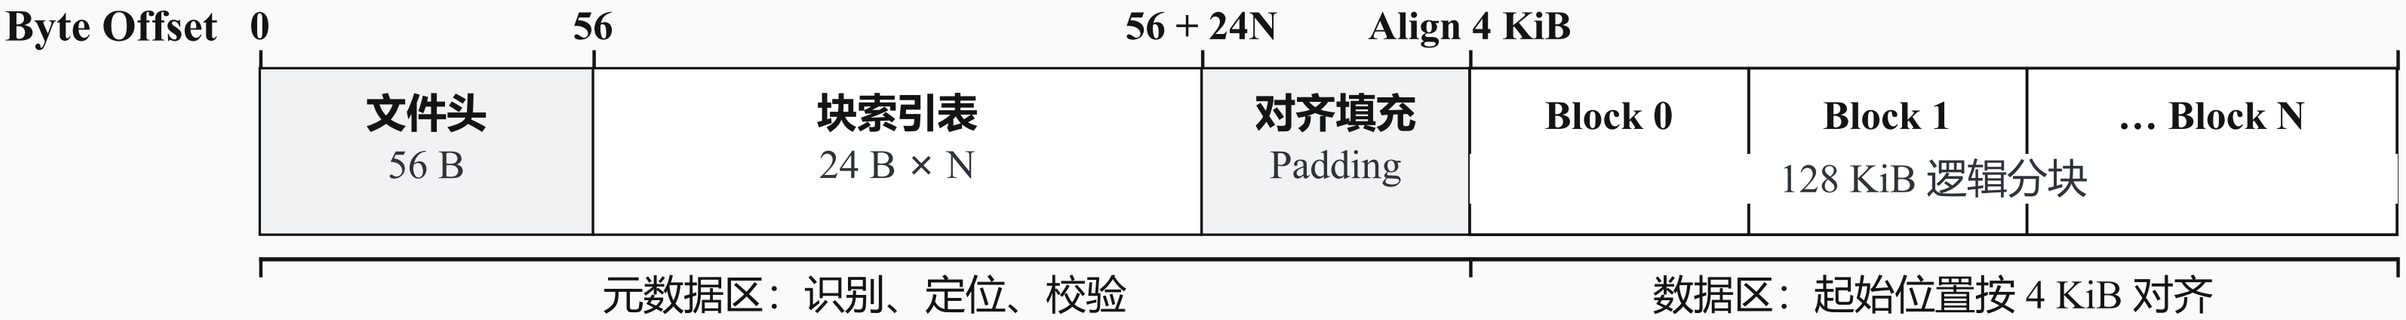
对象状态对应用一致

- RAW
- COMPRESSED
- INLINE

三种对象都向应用返回相同的逻辑内容和长度。

02 解决方案——GPUC 自描述文件组织

文件组织： 固定文件头 + 分块索引 + 4 KiB 对齐数据区



56 B 文件头

格式识别	逻辑大小	分块信息	状态与算法	索引边界	时间信息
magic / version	orig_size	block_size / N	state / algo	header_size	mtime / ctime

24 B 块索引

原始长度	压缩长度	物理偏移	数据校验	保留字段
orig_len · 4 B	comp_len · 4 B	offset · 8 B	CRC32 · 4 B	reserved · 4 B

随机访问

请求逻辑块 i → **索引读取 offset** → **直接定位 Block i**

≤ 1 KiB 小文件：文件头后直接存放 INLINE 数据，不创建块索引表。

文件头负责识别对象，块索引负责随机定位与 CRC32 校验，数据区保持 4 KiB 对齐。

02 解决方案——统一后端接口支持算法切换与 CPU 回退

输入：压缩块批次、算法类型和逻辑范围 → 输出：逻辑数据与 CRC 校验结果

算法	CPU路径	GPU路径
SGLZ	SGLZ CPU	SGLZ GPU (NVIDIA/智铠)
LZ4	liblz4	NVIDIA路径

统一调度与回退

- 支持单块与批处理
- 小请求可选择 CPU
- GPU 初始化失败或设备不可见时回退 CPU
- 上层调用方式保持一致

识别算法 → **选择 CPU 或 GPU** → **校验结果** → **必要时回退 CPU**

项目不是只接入单一GPU内核，而是统一多算法、多后端与回退语义

02 解决方案——前台写 RAW，后台压缩并原子替换

前后台解耦：压缩延迟不进入前台写路径

前台路径 应用只等待普通写入完成，不等待压缩任务。

应用写入
write / pwrite

→

Hook 写 RAW
维护 Header 与逻辑长度

→

close 返回
RAW 已完整且可读

文件关闭后进入后台候选队列

后台路径 Daemon 构造独立临时文件，正式 RAW 始终保持可读。

Daemon 扫描
发现已关闭 RAW

→

批量压缩
写入 .gpuc_tmp

→

完整性落盘
CRC32 + fsync

↓

rename 原子替换
一次切换正式对象

失败或压缩收益不足
删除 .gpuc_tmp；原 RAW 不变

关键边界：只有临时文件完整写入并 fsync 成功后，才允许执行 rename。

正式对象的状态变化

RAW
正式路径对象 · 始终可读

Daemon 创建候选文件

↓

.gpuc_tmp
后台候选对象 · 应用不可见

完整写入 + CRC32 + fsync + rename

↓

COMPRESSED / INLINE
rename 后成为正式对象

候选处理失败
丢弃临时文件，RAW 继续有效

前台close不等待压缩；后台以临时文件完成校验和落盘，rename失败时仍有有效RAW可读。

02 解决方案——读取路径同时处理索引、传输、解压和校验

解析逻辑范围 → 定位块索引 → 批量读取 → 传输至 GPU → 解压并回传 → CRC 校验 → 返回应用

长期GPU Worker复用资源

- GPU上下文与Stream
- 数据流与事件
- 固定页内存与复用缓冲区

读取调度处理

- 合并逻辑范围内的块请求
- 自适应预读减少碎片化调用
- 小请求或 GPU 不可用时走 CPU
- 校验通过后才返回应用

真实成本 = I/O + 数据传输 + 任务调度 + 解压计算，而不是单个内核时间。

长期工作进程与批处理用于摊薄重复初始化、调用和传输的固定开销。

02 解决方案——正确性与故障处理覆盖正常链路之外的问题

01

数 据 正 确 性

- 块级 CRC 检查
- 测试前后 SHA 对比
- 格式、偏移与长度边界检查

02

并发与生命周期

- 文件描述符引用计数
- 共享状态加锁
- 资源在锁外销毁

03

兼 容 处 理

- mmap 使用 userfaultfd 路径
- 环境不支持时同步回退

04

故 障 处 理

- GPU 不可见时回退 CPU
- ENOSPC、SIGKILL、中途重启不替换 RAW
- rename 前异常保留原文件

性能路径可以失败或回退，但数据内容和原文件状态必须保持可控。

03

创新设计

概括项目在机制组合、资源卸载和验证方法上的主要贡献。

03 创新设计——三层创新贯通透明接入、GPU 卸载与国产平台

创新从系统机制向下延伸到压缩算法，并向国产 AArch64 平台扩展

01 架构层

写入、压缩与解压解耦

前台：Hook 写 RAW
业务写入**不等待压缩**

→

后台：Daemon Batch
临时文件 + **fsync + rename**

→

在线：长期 GPU Worker 解压
CPU/GPU 后端切换与失败回退

前台写入不等待压缩，后台原子封存，读取按任务规模选择 CPU/GPU 后端。

02 算法层

自主设计 GPU算法

Simple GPU Lempel–Ziv（SGLZ）

面向GPU批处理的自研 LZ77 变体

128 KiB Block
统一存储处理粒度

→

32 × 4 KiB Chunk
块内并行与不可压缩回退

→

GPU 并行压缩 / 解压
同时提供 CPU SGLZ 兼容路径

03 平台层

国产CPU/GPU适配完成

x86_64
V100 / RTX 4090 已验证

→

统一格式与 CPU 回退
隔离 NVIDIA/智铠后端差异

→

鲲鹏 920 + 智铠100
CPU/GPU 功能闭环与压力验证通过

统一文件格式、Hook、Daemon 与 SGLZ 路径已跨x86_64 + NVIDIA 和鲲鹏 920 + 智铠 100 复用。

验证闭环：POSIX / CRC / SHA 正确性，fio / Vdbench 存储测试，SQLite / PCM 业务与资源测量。

三层创新 = 前后台解耦 × 自研 SGLZ 算法 × 国产 CPU/GPU 跨架构落地

04

实验结果

按实验设计、共机性能、兼容性、稳定性和资源卸载依次给出证据。

04 实验结果——实验按正确性、性能与资源占用三条线展开

正确性

数据完整性、解压缩一致性、端到端无误码

性能

I/O 带宽、时延、并发吞吐、业务 QPS

资源占用

CPU 利用率、DRAM 带宽、GPU 状态与系统开销

目的	工具或指标
I/O 与时延	fio：带宽、IOPS、平均时延与尾时延
并发读取	Vdbench：顺序/随机、多线程、混合负载
业务影响	SQLite：QPS 与 p99 延迟
CPU 与系统资源	pidstat、sar、perf
DRAM 带宽	Intel PCM
GPU 状态	nvidia-smi、ixsmi 与项目内部计数
数据正确性	SHA 与 error 计数

测试平台

RTX 4090：核心卸载、SQLite、fio/Vdbench 与一小时稳定性

Tesla V100：约 4 GiB/s 同吞吐 Intel PCM 主机 DRAM 对照

鲲鹏 920 + 智铠 100：AArch64 CPU/GPU 闭环、传输 A/B 与压力验证

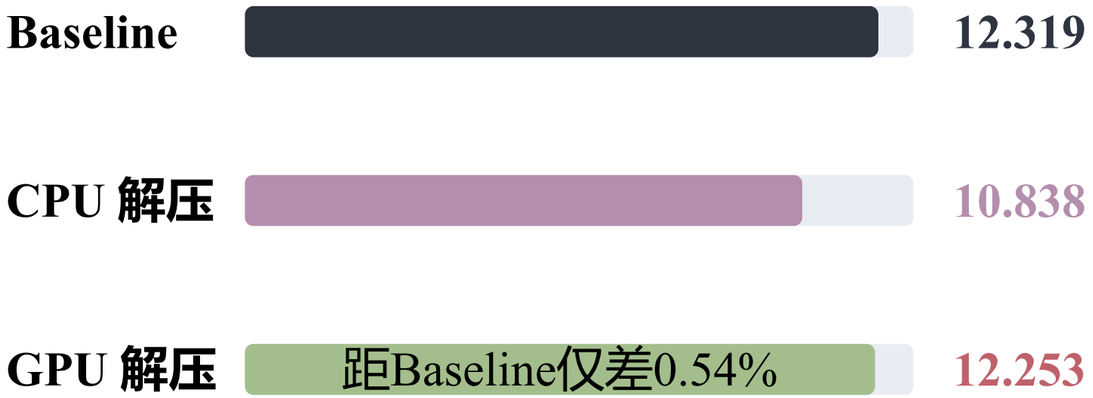
统计方法

核心短测重复**5**轮，报告均值与**95%**置信区间；稳定性实验连续运行**1 小时**。所有结论可追溯至 results/final/ 中的日志、CSV 或汇总文件

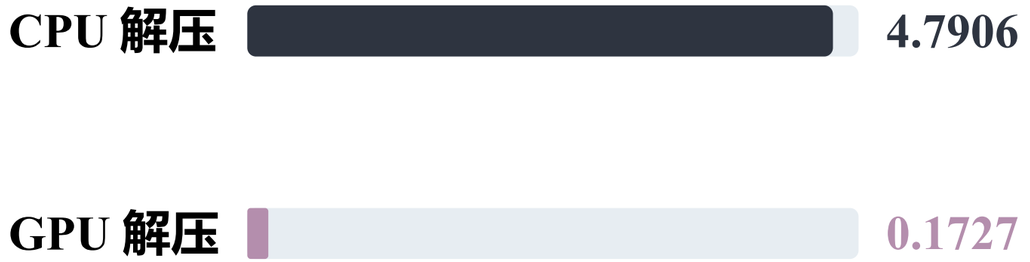
04 实验结果——约 4 GiB/s 解压负载下，GPU 基本恢复业务吞吐并显著减少 CPU 时间

条件：RTX 4090，5轮；4个CPU业务线程；CPU/GPU处理同批LZ4，均约4096 MiB/s。

合成业务吞吐（10^8 ops/s）



解压相关 CPU 时间（s）



+13.05%
GPU 相对 CPU 的业务吞吐

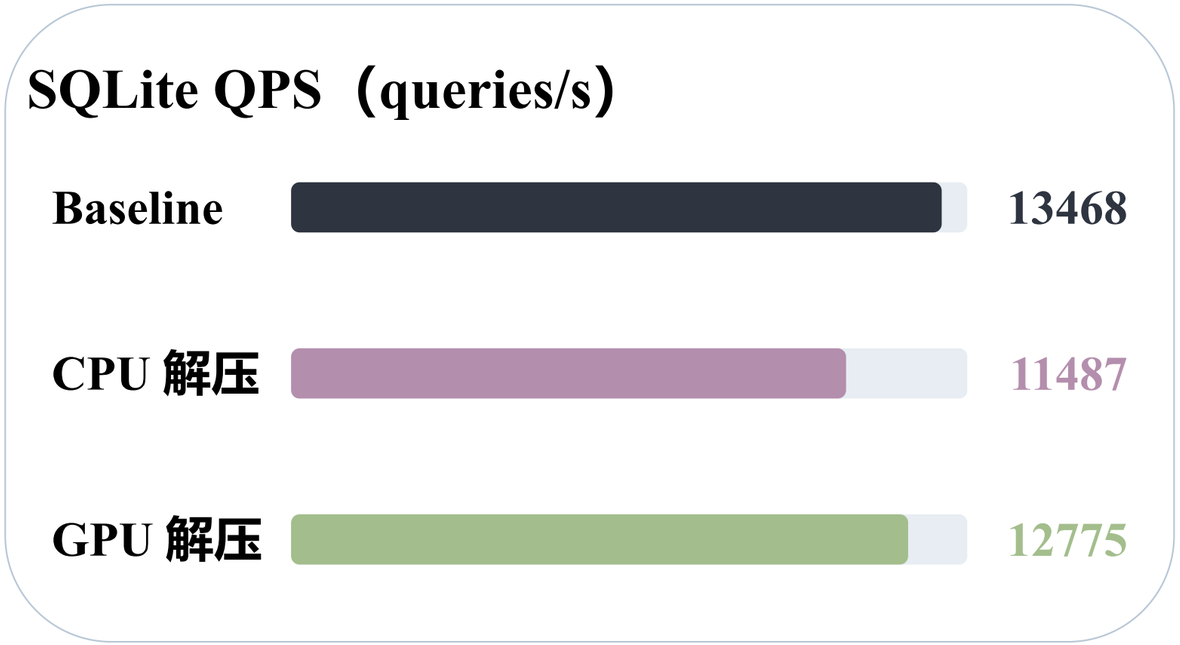
-96.4%
GPU 相对 CPU 的解压时间

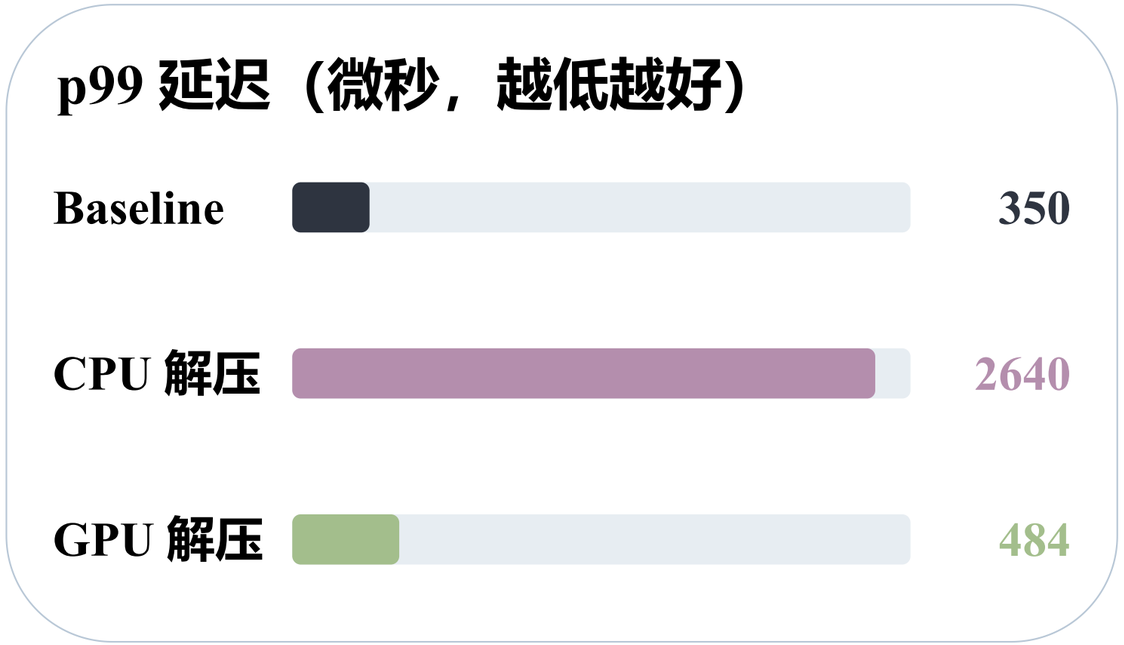
-0.54%
GPU 与 Baseline 的吞吐差距

该场景中 GPU 的主要价值是降低解压与业务之间的 CPU 争用，而不是让存储介质变快

04 实验结果——SQLite 实验显示 GPU 解压降低共机干扰，但未超过无解压基线

条件：RTX 4090，5轮；10万行×512 B，4个只读查询进程，与约4096 MiB/s LZ4解压共机。





+11.21%
QPS：GPU 相对 CPU 解压

-81.66%
p99：GPU 相对 CPU 解压

-5.14%
GPU QPS 相对 Baseline

GPU 没有加速 SQLite 本身，而是减轻了共机解压对 SQLite 的干扰。

04 实验结果——fio 与 Vdbench 证明接口可用和数据正确，也暴露小随机读边界

平台：RTX 4090

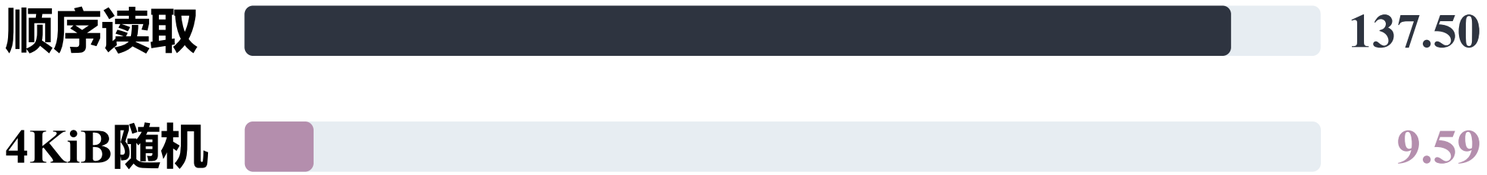
fio 正式测试

- SGLZ/LZ4，4/16/128 KiB
- 1/4 线程，每组重复 5 次
- 共 60/60 个样本完成
- error=0、无超时、SHA 一致

Vdbench 正式测试

- 256 MiB 文件、4 线程
- 2 秒预热、10 秒计时、重复 5 次
- 顺序读、随机读与 70:30 混合读写
- 50/50 个样本完成，逻辑 SHA 一致

Vdbench LZ4代表读取带宽（MiB/s）



性能边界

两者均低于普通文件路径；小随机读的固定开销尤其明显。

正式工具验证了接口兼容性与数据正确性，但当前原型并非所有 I/O 模式都能获益。

04 实验结果——一小时稳定读取无错误，确定性软件故障能够保留或恢复有效数据

平台：RTX 4090

3600 s	473.79 MiB/s	error=0	SHA 一致
实际运行时间	平均吞吐	读取错误	前后内容

已执行的软件故障测试

- ENOSPC
- 压缩进程 SIGKILL
- 临时文件残留后重启
- GPU 不可见时 CPU 回退
- /dev/full：错误正确向上传播

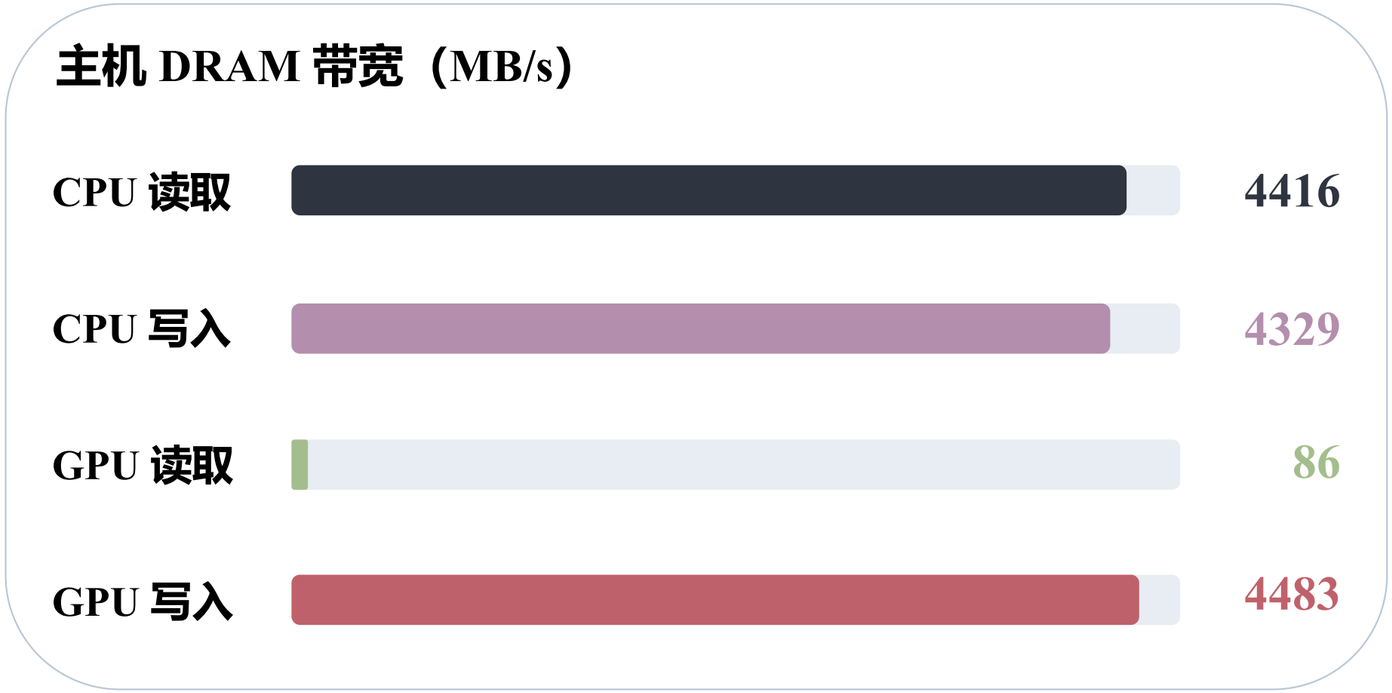
本次实验的明确边界

- 数据量：512 MiB
- 块大小：128 KiB
- 并发：4 个任务
- 真实掉电未覆盖
- 真实 GPU reset 未覆盖

实验支持“一小时持续读取正确”和“确定性软件故障有效”，不代表完成生产级灾难恢复验证。

04 实验结果——V100 同吞吐条件下，GPU 路径降低 47.75% 主机 DRAM 带宽

条件：V100 平台；CPU 与 GPU 路径均维持约 4093 MiB/s 的解压吞吐



8745.46

CPU 路径合计 MB/s

4569.51

GPU 路径合计 MB/s

原因解释

GPU 路径减少主机侧压缩输入读取，但解压结果仍需写回主机内存。

-47.75%

GPU 相对 CPU 的总带宽

该结果表示特定负载下的内存带宽下降，不等同于 RSS 或内存容量下降。

04 实验结果——鲲鹏 920 + 智铠 100 完成国产 CPU/GPU 功能闭环

环境：openEuler 22.03 | 2 路 64 核鲲鹏 920 / AArch64 | 智铠 100 32 GiB | 128 KiB Block × 32 Batch

PASS 鲲鹏 920 CPU 路径

AArch64 原生构建

POSIX + 2000 个格式 Fuzz

16 MiB 端到端透明读取
内容与 SHA-256 一致

PASS 智铠 100 GPU 路径

SGLZ 单元与集成测试

混合块 / INLINE / 并发 pread

16 MiB GPU Daemon 压缩
透明读取 SHA-256 一致

32-Block 合并传输 A/B

包含打包、传输与Kernel，不含磁盘I/O

压缩	**845.929 → 985.727**	MiB/s	**+16.5%**
解压	**688.415 → 718.622**	MiB/s	**+4.4%**

扩大正确性压力

16 GiB

131072 Blocks
Round-trip PASS

1 GiB

大文件连续透明读取 3 次
SHA-256 全部一致

热路径与大文件正确性通过

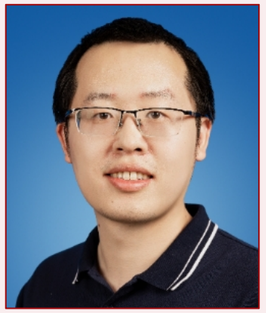
统一GPUC文件格式、自研SGLZ与透明访问链路，已完成x86_64/NVIDIA→ 鲲鹏920/智铠100的跨架构复用。

05

团队与总结

团队分工、代码来源边界、项目结论和后续演进方向。

➢ 05 团队与总结——指导教师把关方向，三名学生完成跨平台工程闭环



聂世强

指导教师

选题构思与总体技术路线指导

与队长讨论并确定项目方向，提出 GPU 卸载存储压缩的核心思路。



刘松

指导教师

系统方案、实验设计与答辩指导

对系统边界、实验方法、结果表达和决赛材料进行审阅与把关。



朱嘉乐

队长 · 系统架构与国产适配

Hook、Daemon、后端与国产适配

负责 SGLZ/nvCOMP 接入、鲲鹏 920 + 智铠 100 适配、系统联调和总体交付。



贾茹

队员 · 存储与 I/O 优化

预读、mmap、内存与性能评测

负责 I/O 路径优化、测试设计和性能数据复核。



边程曦

队员 · 材料与成果表达

文档、PPT、视频与提交材料

负责项目材料整理、演示制作和提交内容校对。

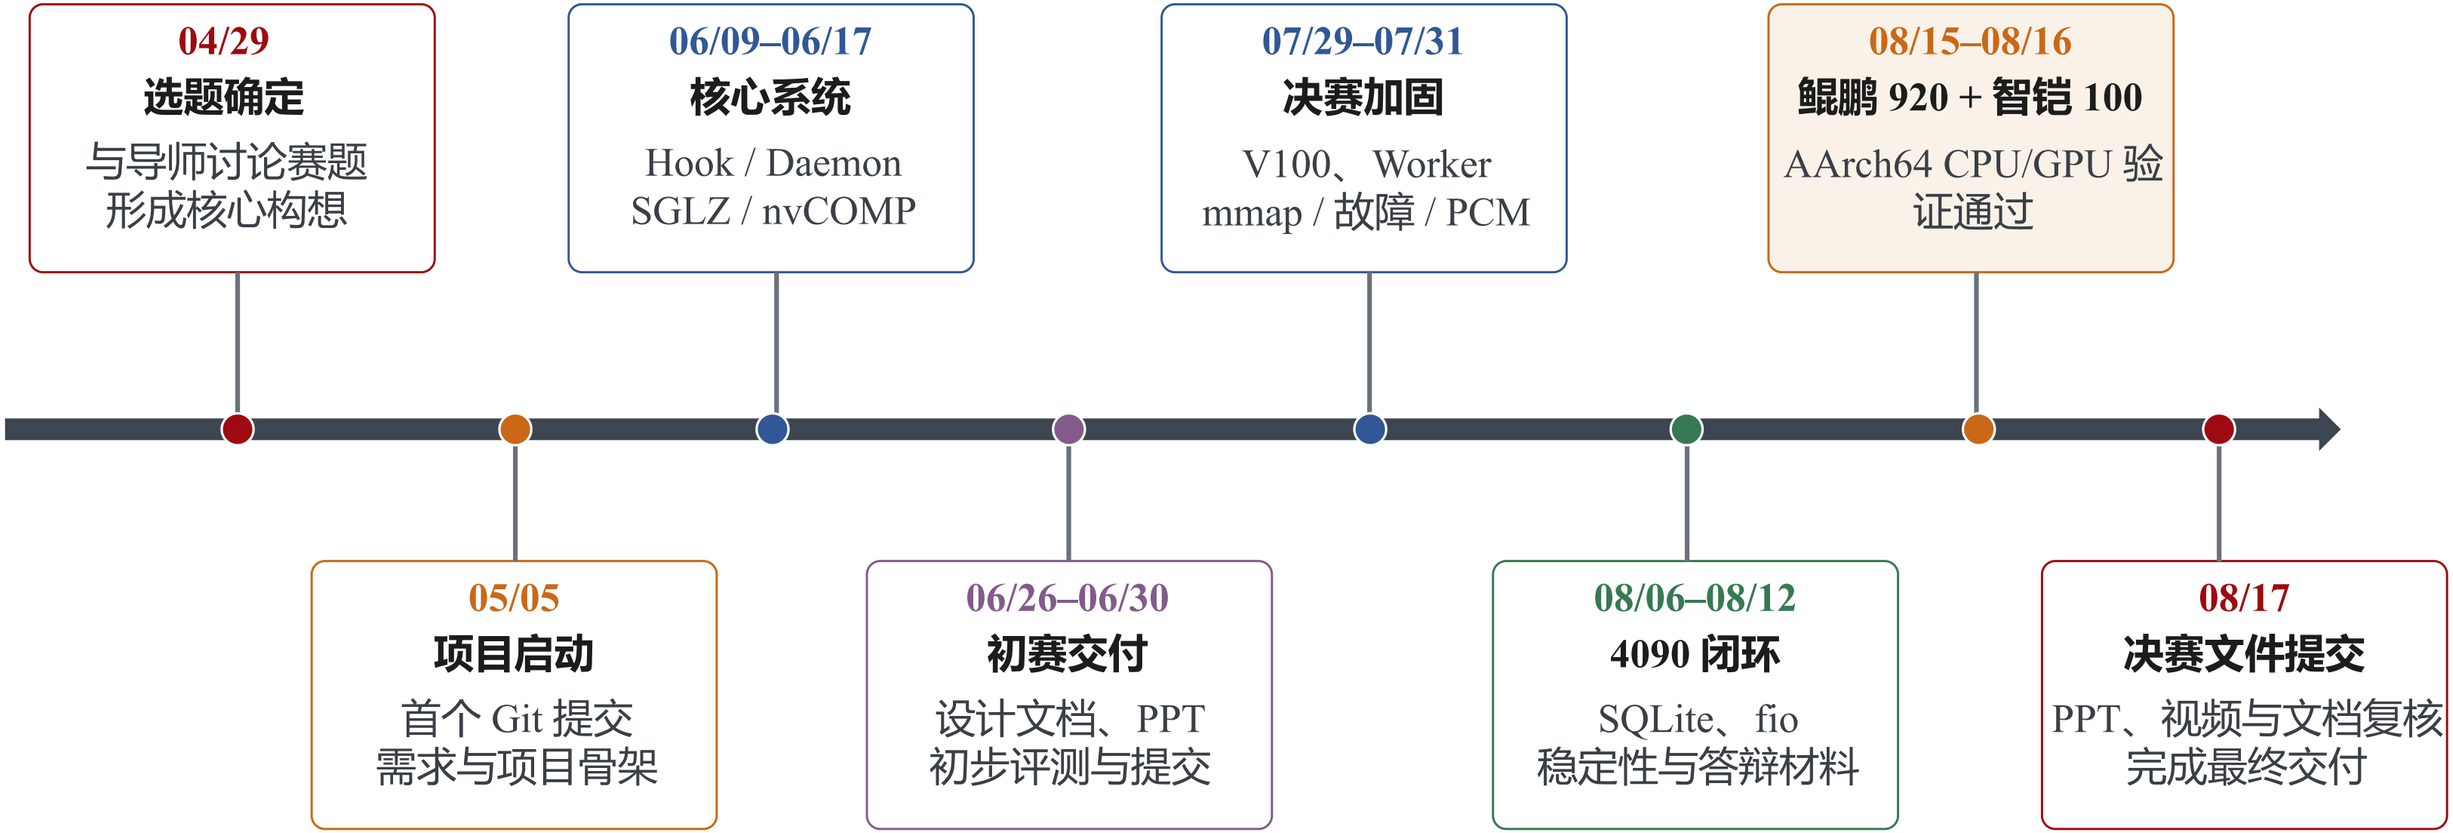
导师提供方向与方法把关，三名学生协同完成系统实现、算法接入、国产适配、实验验证与答辩交付。

➢ 05 团队与总结——从4月选题到8月决赛交付

初赛
03/18 00:00 — 06/30 23:59

决赛阶段 1
07/17 21:51 — 08/18 23:59

决赛答辩文件提交
08/13 14:43 — 08/18 12:00



Git 记录覆盖：原型实现 → 性能优化 → V100/RTX 4090 复测 → 答辩材料 → 鲲鹏 920 + 智铠 100 国产平台闭环。

阶段主线：让透明存储压缩从可运行原型，走向跨架构、可验证、可复核的完整系统。

05 团队与总结——作品借鉴边界与本队创新增量

未复用往届作品或 fork 其他项目源码：核心系统由本队独立实现

参考公开技术路线和官方接口，在 CUDA、CoreX、nvCOMP、liblz4 等运行时与工具链之上，完成端到端工程集成与机制创新。

参考与借鉴边界

- 未基于往届作品或其他项目源码开发
- 参考 DM、Btrfs、OpenZFS 等公开路线
- 参考论文、官方文档与公开接口
- 第三方来源及许可证均可追溯

本队独立实现

- GPUC 文件格式、块索引与校验机制
- 透明 I/O Hook 与后台压缩 Daemon
- SGLZ CPU/GPU 兼容后端支持 NVIDIA 与智铠 100
- mmap、回退、故障恢复与实验框架

创新性与增量工作

- 透明访问、后台压缩与 GPU 解压的端到端组合
- Worker、Batch、Pinned Memory 与传输合并
- 请求感知预读、小请求分流与失败回退
- 鲲鹏 920 + 智铠 100 国产平台适配

第三方边界： CUDA、CoreX、nvCOMP、liblz4为运行时库；fio、Vdbench、SQLite、PCM 为测试工具。

AI 辅助： 用于部分代码辅助、审阅、测试脚本和文档整理；架构、实验与结论由团队确认。

05 团队与总结——论文与技术资料

[1] Song 等，Breathing new life into compression: Resolving the dilemma of LFS with compression on flash storage，Journal of Systems Architecture，2025。doi:10.1016/j.sysarc.2025.103432

[2] Peñaranda 等，Hybrid-Smash: A Heterogeneous CPU-GPU Compression Library，IEEE Access，2024。doi:10.1109/ACCESS.2024.3371253

[3] Tan 与 Zhu，OCM: An Overcapacity Mapping-Based Virtual Disk Approach for Large-Scale Storage，Electronics，2025。doi:10.3390/electronics14204091

[4] Dakic 等，High-Performance Computing Storage Performance and Design Patterns—Btrfs and ZFS Performance for Different Use Cases，Computers，2024。doi:10.3390/computers13060139

[5] Cho 等，RFUSE: Modernizing Userspace Filesystem Framework through Scalable Kernel-Userspace Communication，FAST 2024。usenix.org/conference/fast24/presentation/cho

补充资料：Linux Device Mapper、Btrfs、OpenZFS、FUSE/ublk、nvCOMP 与 CUDA Runtime 官方文档。

西安交通大学
XI'AN JIAOTONG UNIVERSITY

CSCC 全国大学生计算机系统能力大赛

谢谢各位老师，敬请批评指正！

2026 全国大学生计算机系统能力大赛 — OS 功能挑战赛道

西安交通大学 · 队伍 **404notfound**

成员：朱嘉乐（队长）、贾茹、边程曦　　指导老师：聂世强、刘松